

Challenge LINCOLN: 6ème édition

« Je redoute trois journaux plus que 100.000 baïonnettes » Napoléon Bonaparte

Le challenge Data Science, c'est :

- Participer de manière collaborative
- Monter en compétence sur des outils, des nouvelles problématiques
- Partager et découvrir des nouvelles méthodes analytiques
- S'amuser et laisser libre cours à sa créativité

...dans une ambiance conviviale et sans pression!







Equipes



Thématique

Traitement de journaux et d'émissions Radio



Données

Image de journaux – Textes d'émissions



Livrables

Données qualifiées & Présentation



Critères d'évaluation

Performance, Démarche & Restitution



Planning



13 équipes



Tiphaine VAULEON
Claire UTIEL



Moctar EL MAHJOUB
Juanita DAGNON



Louis-Alexandre BAYOL
Oualid AITBOUHOU
Martin FELDMAN



Liang LIANG
Dorian FREMONT



Lydia VIJAYARAJAH Jeanne CELERIER



Fayçal BENSAID

Abderrahim TALEB



Thomas NICOLAS

Julien-Yacine CHAQRA



Steven MACAIGNE



Antoine HAMON



Axel-Philippe GUEHI



Jack SWINDLE



Antoine VOKLEBER



Théo DAVILLE





Objectif du challenge

- Traiter un sujet lié à l'actualité à partir des sources de données proposées
 - Images PDF de quotidiens sur le mois de septembre 2019
 - CNEWS
 - 20 minutes
 - Transcription d'émissions Radio sur le mois de septembre 2019
 - RTL
 - France inter
 - Europe 1















Quelques propositions de sujets















- Segmentation de la page afin d'extraire la structure et l'information du journal
- Détection et description des publicités
- Comparaison du traitement d'un sujet d'actualité entre deux journaux
- Détection et résolution automatique de jeux

- Création de résumé de l'actualité
- Détection des personnes et de leur rôle dans l'émission
- Comparaison du traitement d'une information entre émissions de Radio

Vous êtes libre de créer votre propre sujet!

Seule contrainte : utiliser les données fournies





Extraction de la structure et de l'information

SPORTS

Ce quelque chose de dionysien...

Football Andorre, 136º nation mondiale, aura droit aux honneurs du Stade de France (20h45). que les Bleus ne quittent décidément plus

gros matchs qualificatifs pour la capi-tale. Ce mardi (20h45), les supporters les Bleus continuent à organiser les seront 50 000 à remplir les anneaux du rencontres qualificatives à un tournoi Stade de France pour voir l'équipe de majeur - même celles qui ne font pas France affronter la 136° nation mondiale réver – au Stade de France.

en notre faveur. » Ildefons Lima s'en rèdans le cadre des éliminatoires de l'Euro

Et pour cause. Luc Holtz, l'homologue jouit quand même. « Rien qu'en recon-Bleus dans l'enceinte dionysienne.

« Des ondes positives »

Les amicaux pour la province, et les fait partie du patrimoine, on l'asso

Didier Deschamps, n'a jamais envisagé témojoné de sa colère, en septembre frissons qu'à l'époque, témojone le caailleurs qu'à Saint-Denis. D'autant plus 2017, de devoir affronter les Bleus à pitaine andorran, qui était présent pou que ce sera le centième joué par les Toulouse plutôt qu'à Saint-Denis. Il y le premier match des Bleus après leur trouvait même un écho pour trans- titre mondial, en 1998. Pouvoir particicender ses hommes lors de la cause- ner au centième match de la France rie d'avant-match, sur l'air « On est tel-Une chose est sure l'équipe de France lement des plouss pour eux qu'ils pous de respect » On ne poussera pas le jouent dans un stade de kermesse ». vice jusqu'à lui faire le coup de l'im nant celui d'une génération peut-être - Résultats - 0.0 et « 0.0 » qui décide de mensité du stade qui ferait crever ses France-Ukraine, en 2015. « Cette ren- mettre fin aux tournées dans l'Hexa- équipiers de trouille. Andorre a tenu le contre (3-flancés avoir perdu l'aller 2-fil) none l'intérêt sportif avant tout « Le ... (3-flancés avoir perdu l'aller 2-fil) none l'intérêt sportif avant tout « Le ... (3-flancés avoir perdu l'aller 2-fil) a marqué les mémoires pour qui était Stade de France paraît plus grand que et l'ambiance stambouliote, par rapprésent ce jour-là, se souvient le por-tier Hugo Lloris. Le Stade de France d'espace, assure Deschamps. Ca joue autre chose. Julien Laloye



2020. Un match que le sélectionneur, luxembourgeois de Deschamps, avait naissant la pelouse, j'ai eu les mêmes

Une équipe remaniée

en conférence de presse mardi. dans son onze de départ par samedi (4-1). « Cela me semble des Bleus. Ce ne sera nas Le technicien a assuré que e défenseur Lucas Hernandez qui avait recu un coun lors de France-Albanie, était apte pour le rendez-vous face à Andorre.

les Etats-Unis

Basket Après leur défaite avec la défense qu'on avait proposée « Rodgeur» ? iusque-là », a analysé après le match le capitaine, Nicolas Batum. Mais les Bleus n'ont pas su cette fois freiner les offensives adverses. Même son de cloche du côté du sélectionneur, qu relève le positif. « C'est ca qui crève le cœur, on a fait un match incroyable presque au-delà de ce que je pouvai: espèrer dans le domaine offensif ».

confié Vincent Collet. Et du positif, il en faudra pour les Bleus avant de défier les Etats-Unis, mercredi (13 h). La team US a beau avoi emmené une équipe C ou D en Chine sans aucune de ses grandes stars elle aligne tout de même 12 joueur de NBA que tous donnent favoris pour l'or. Mais tout espoir n'est pas étein « C'est dur parce qu'on n'aime pas perdre, mais on n'est pas morts », a L'Espagnol compte 19 victoires assurė Nicolas Batum.

La France perd | Nadal ne devrait pas se faire prier sur le fil et défiera pour éclipser l'étoile Federer

Tennis 20-19 en 2019, 20-20 en A Flushing Meadows, les blessure 2020 ? Toujours derrière Federer au ont rattrapé Federer et Djokovic nombre de tournois du Grand Chelem « Rafa », lui, semble être revenu : lundi contre l'Australie [98-100], les gagnès, Rafael Nadal a fait un pas son meilleur niveau, sans jamais Français n'échapperont pas au choc en avant en s'adjugeant, la nuit der- perdre son envie de gagner. « La face aux Etats-Unis en quart de fi- nière, l'US Open au détriment du manière dont le match a pris une nale du Mondial chinois. « On ne pou- Russe Daniil Medvedev (7-5, 6-3, tournure dramatique à la fin rend vait pas perdre en marquant 98 points 5-7, 4-6, 6-4). Le début de la fin pour ce jour inoubliable pour moi, a ex-



plique Nadal après son sacre amè ricain. Ce trophée est tellement in portant pour moi. » Et le Taureau de

« Rafa » pourrait détrôner « Rodgeur » lors du prochain Roland-Garros.

Manacor, agé de 33 ans, devrait être en mesure de dompter la chaleur et l'humidité de Melbourne pour être à ie en début de saison. Ensuite, pas peine d'épiloguer sur le résultat Roland-Garros, où Nadal gagnera n 21º tournoi du Grand Chelem. A Federer enfin de remporter une neu pour redonner du suspense à cette Roglic (Jumbo-Visma) a réussi course sans ligne d'arrivée. A.H.

20 secondes

Sacré couac pour les Croates. en 2018, a été accrochée à la surprise énérale par l'Azerbaïdjan (1-1), gui marque son premier point dans l'Euro de football 2020. Dans son groupe, l'équipe de Luka Modris va devoir batailler notamment vec la Hongrie et la Slovaguie

Ngapeth ménagé au début de l'Eurovolley. Lundi, Earvin Ngapeth a passé une IRM révélant une lésion u niveau des côtes, rapporte L'Equipe. La star de l'équipe de France de volley manquera les trois premiers matchs du nampionnat d'Europe contre la Roumanie, jeudi, la Grèce, samedi, et le Portugal, dimanche

leader de la Vuelta. Le Danois Jakob Fuglsang (Astana) a remporté, lundi, la 16º étape du Tour d'Espagne au sommet de La Cubilla. Un temps mis en à accentuer son avance au général

Paae

Ce quelque chose de dionvsien...

Football Andorre, 136º nation mondiale, aura droit aux honneurs du Stade de France (20h45), rue les Bleus ne quittent décidément plus

cadre des éliminatoires de l'Euro Et pour cause. Luc Holtz, l'homologue Un match que le sélectionneur, luxembourgeois de Deschamps, avait

20. Un motor que la selectionne.

Laurebourgareis de Discharge, aixet
freiberburgarei, praiparei inschargei, praiparei inschargei, praiparei inschargei in

dans son onze de départ par rapport au match face à l'Albani samedi (4-1). « Cela me semble

Article



20 secondes

Sacré couac pour les Croates Lundi, la Croatie, finaliste du Mondial en 2018, a été accrochée à la surprise générale par l'Az erbaïdjan (1-1), qui marque son premier point dans la course à la qualification pour l'Euro de football 2020. Dans son groupe, l'équipe de Luka Modric va davoir hatailler notamment

avec la Hongrie et la Slovaguie.

Ngapeth ménagé au début de l'Eurovolley. Lundi, Earvin Ngapeth a passé une IRM révélant une lésion au niveau des côtes, rapporte L'Equipe. La star de l'équipe de France de volley manquera les trois premiers matchs du championnat d'Europe contre la Roumanie, jeudi, la Grèce, samedi, et le Portugal, dimanche

Fuglsang vaingueur, Roglic solide leader de la Vuelta, Le Danois Jakob Fuglsang (Astana) a remporté, lundi, la 16º étape du Tour d'Espagne au sommet de La Cubilla. Un temps mis en difficulté, le maillot rouge Primoz Roglic (Jumbo-Visma) a réussi

Sacré couac pour les Croates.

Lundi, la Croatie, finaliste du Mondial en 2018, a été accrochée à la surprise générale par l'Azerbaïdjan (1-1), qui marque son premier point dans la course à la qualification pour l'Euro de football 2020. Dans son groupe, l'équipe de Luka Modric va devoir batailler notamment avec la Hongrie et la Slovaguie.

Article



Rubrique à accentuer son avance au général.



Extraction de la structure et de l'information

Thématiques

- Document Layout Analysis
- Zone segmentation
- Texture segmentation
- Optical Character Recognition (OCR)

Champs d'application

- Extraction de données
- Création de modèles de données

- Multitask handwritten document layout analysis :
 - https://arxiv.org/pdf/1806.08852v3.pdf
 - https://github.com/lquirosd/P2PaLA
- OCR :
 - Tesseract, google vision ...

- Segmentation de page par recouvrement des espaces blancs :
 - https://hal.inria.fr/hal-00779235/document
- Texture segmentation :
 - http://arima.inria.fr/006/pdf/arima00604.pdf





Détection et description des publicités

ACTUALITÉ

Un droit fécond en interrogations

Bioéthique Manque de donneurs, de moyens... La procréation médicalement assistée (PMA) pour toutes pose certains défis pratiques

On parte beaucoup FIV, don de sperme deux ans. Ce détai risque donc de s'alment assistée [PMA] pour avoir un en-sition qui pourrait en refroidir certains. tant ont commence mardi filte cudes. sous). Mais, dejà, certaines associations Stocks de sperme détruits ? pour toutes soit réellement assurée.

effet, les auditions à la commission spébioéthique introduit plusieurs changeciale chargée d'examiner le projet de loi ments, au-delà de la PMA pour toutes. sur la bioéthique, qui prévoit notamment Notamment la possibilité pour les ende donner la possibilité aux couples de fants nès d'une PMA avec don d'avoir lesbiennes et aux femmes seules de accès, s'ils le souhaitent et à leur majorecourir à une procréation médicale- dué à l'identité du donneur. Une disno-

et certains médecins veuient faire pres- Deux ième problème, le texte prévoit la sion pour que le texte ne passe pas à destruction du stock de gamètes ac- pu déménager, par exemple. On peur Face à ces défis, 350 professionnels de côté d'un point essentiel : les conditions tuel un an après la promulgation de matérielles pour garantir que cette PMA la loi pour éviter la coexistence des bliquement les anciens donneurs à se la loi permette à d'autres centres pu-



tériellement impossible, certains ont vient Catherine Guillemain

paillettes, serait de recontacter tous commission spéciale bioéthique. Mais les donneurs » Mais au cabiner de la puand bien même, « Sans changemen claires Il est hors de question de re- du mai à rénondre à la demande accontacter tous les donneurs. C'est ma- tuelle et à celle qui se profile », prè-

en revanche envisager d'appeler pu- la PMA demandent via une pétition que

(Erès), vous évoquez la question du blen-é ire de ces enfants é levés sans père. Que disent les études? Certains reprochent au projet de loi de Est-ce un handican? Toutes les études américaines montrent que le développe ment des enfants nés de PMA dans une familie hétérosexuelle, homosexuelle de femmes seules, n'offre aucune différence avec celui des entants nés de facor naturelle». De plus, quand on interroge ces enfants nés dans des couples

manque de sperme et l'éventuelle balsse de dons de gamètes. Est-ce un risque qu'il faut prendre en compte ? Bien sûr. Il suffirait que l'Agence de la biomédecine lance des maintenan



1. Extraction de la publicité



2. Description de la publicité

- **Publicité**
- Masha et Michka
- Ours et enfant qui tient une loupe
- 10 dernières représentations









Détection et description des publicités

Thématiques

- Document Layout Analysis
- Optical Character Recognition (OCR)
- Clustering
- Scene Parsing / Image captioning

Champs d'application

- Extraction de données
- Analyse textuelle
- Génération automatique de données

- Scene parsing / Semantic segmentation
 - https://github.com/CSAILVision/semantic-segmentation-pytorch
 - https://www.tensorflow.org/tutorials/text/image_captioning
- OCR: Tesseract, google vision ...
- Text clustering : http://charuaggarwal.net/text-cluster.pdf
- Embeddings: https://fr.wikipedia.org/wiki/Word_embedding






Comparaison du traitement d'un sujet d'actualité entre 2 journaux

L'ANCIEN PRESIDENT JACQUES CHIRAC EST DECEDE A L'AGE DE 86 ANS

LA FRANCE DANS LE CŒUR



L'homme d'Etat laissera une empreinte indélébile sur la politique de son pays, tout en restant extrêmement populaire.

Une figure de la Vº République. De la Corrèze à l'Elysée

Jacques Chirac, président de 1995 à 2007, est décédé à l'âge de 86 ans, a annoncé hier sa famille. Pluie d'hommages venant de personnalités de tous bords, minute de silence à l'Assemblée et au Sénat, drapeaux en beme à Paris, deuil national lundi. Hier soir, Emmanuel Macron a tenu à rappeler «l'amour de la France et des Français » que porta it celui qui «occupa les plus hautes fonctions sans lamais oublier ses raidnes». Cette nouvelle a provoqué d'autres réactions «Chidni» sur tous durant ses douze années à la tête du pays, et plus de quarante à différents postes de pouvoir.

De ses premiers pas en politique en tant que conseiller municipal et député de Corrèze, en 1967, jusqu'à son accession à l'Elysée, en 1995, la cques Chirac a tout connu. Secrétaire d'Etat et ministre à plusieurs reprises sous Charles de Gaulle et Georges Pompidou, cet anden de l'ENA a été nommé Premier ministre par Valéry Giscard d'Estaing en 1974. Preuve de son tempérament, il n'a pas hésité à démissionner en 1976, ne s'entendant pas avec VGE. C'est émues, illustrant l'impact qu'aura eu alors qu'il a fondé le RPR (devenu UMP. puis Les Républicains), et s'est lancé à la conquête de la mairie de Paris, qu'il a dirigée de 1977 à 1995. Durant cette

période, il est devenu, de 1986 à 1988, le premier chef d'un gouvernement de cohabitation, sous François Mitterand. S'il a échoué à s'imposer face au chef d'Etat socialiste en 1988, ce revers n'a fait que renforcer sa détermination. En 1995, il s'est ainsi lancé corps et âme dans la course à la présidentielle malgré la candidature de son «ami» du RPR, Edouard Balladur, et a accédé enfin à la fonction suprême en battant le socialiste Lionel Jospin. Dès son entrée à l'Elysée, Jacques Chirac a été au cœur d'une polémique, en annonçant la relance des essais nu déaires français. Mais il a aussi été l'homme qui a mis fin au septennat présidentiel, en 2000, et qui a incarné le rempart contre le Front national de Jean-Marie Le Pen durant la présidentielle 2002. Quant à son second mandat, il a été marqué par son refus de s'impliquer dans la querre en Irak lancée par le président américain George W. Bush, en 2003.

BIO EXPRESS

29 NOVEMBRE 1932, Jacques Chirac naît à Paris. Enfant unique, Il intégrera Sciences-Po, avant d'épouser Bernadette, dont il aura

967. Après un premier mandat de conseiller l'énarque devient député de Corrèze. Il rejoint dans la foulée le gouvernement Pompidou.

1974. Il démissionne de Matignon. fonde le RPR et trois ans plus tard. devient maire de Paris. Il redeviendra Premier ministre en 1986.

1995. Il est élu président de la République, avec 52% des voix. contre le candidat socialiste Lionel

2002. Il est réélu à 82 % des voix contre Jean-Marie Le Pen, après l'élimination surprise du même Lionel Jospin au premier tour.

Nostalgie et sympathie

Mais il n'aura ja mais été aussi apprédé que depuis son départ de l'Elysée, en 2007. Ses multiples apparitions au Salon de l'agriculture, son style, ses phrases cultes, ont en effet marqué plusieurs générations. A tel point que chacune de ses sorties publiques, en Corrèze ou à Saint-Tropez, inspiralt nostalgie et sympathie. Victime d'un AVC en 2005, ses ennuis de santé à partir des années 2010 avaient soulevé des inquiétudes. Mais malgré son absence publique, la France ne l'avait ja-

L'INFO EN PLUS

Lorsqu'il a démissionné de son poste tique pour ouvrir une galerie d'art»

GRAND PARIS

La capitale «en deuil»

Hommage

Dans l'ancien QG de Jacques Chirac, on se souvient de l'homme. du maire, des affaires

La nouvelle a cuelli les élus, jeudi matin, en pleine conférence de presse en amont du Conseil de Parts, Jacques Chirac, acteur omnignéeent de guatre 1 discermise de la vie politique française et internationale, est mort à son domicile parteien à l'âge de 86 ans. L'Hôtel. deVille, où le premier maire de la capitale a prisises quartiers en 1777, se met spudain en brania. Entre larmes, souvenirs et moments de battement. Les élus de la droite parisienne se suc-Bertrand Delancé Jean Tibéri et bien cident su micro , en tible Marie-Claire sûr à six mois des élections munici-Carrère-Gée frachementétue prési- pales peux de tous les prétendants dente du groupe LRI (Les Républicains : au poste : Benjamin Gréveaux, Cédric : mis en berne et la tour Effet, étainte et Indépendants). Dette ancienne se- Villani, Gaspard Gantrer. crétaire générale adjointe de l'Elysée - Dans les rangs de la gauche parisous Chiracet consellère ouand (Mait sienne on est en revanche moins maire rend appriantment hommage expressits, < Les emmerdes volent à cette « figure paternelle [...], c'est à l' toujours en escadrille », avait déclaré. Paris que fout a commencé », « Paris - un jour Jacques Chirac, Car Chirac,



En 1977, au soir de son élection.

dans la foulée. Des gens courent dans les couloirs les hommages pleuvent -

pleure son maire », armonce le groupe — maire de Paris, ce n'est pas seulement

Espapile de la cilibère motocrotte et la propreté de la ville en thème de campagne. D'est aussi de nombreux scandales politico-financiera - emplois fictifs buz électeurs affaire des HLM. Pour Lika Filioche, coprésidente du proupe Génération-s. Chirac le chef d'Etat, est même « à l'origine de son engagement militant et politique » avec l'expulsion des sans-papiers de l'église Spint-Ambroise, en 1996.

La tour Effel éteinte

Dama le bursou historique des maires: un portrait de Jacques Chirac, en noir et blanc. Les drapeaux sont en berne. « Paris est en deuil » déclare Anne Hidalgo, e Pour nous les Parisiennes et les Parteiens, il sera à jamais notre mains almost possionnément so ville et ses habitants y a-t-elle siguité sur Teitter: En hommage, les drapeoux des louipements municipaux ont étàjeudi soir. Des registres seront ouverts à l'Hôtel deVille et dans toutes Les mairies d'arrondissement « pour permettre aux Parisiennes et aux Parisiens de Minotoner leur affections, a annoncé Anne Hidalgo.





Comparaison du traitement d'un sujet d'actualité entre 2 journaux

Thématiques

- Sentiment analysis
- Text classification
- Morphological analysis
- Topic modeling

Champs d'application

- Traitement de bases documentaires
- Etudes de verbatims
- Détection de thématiques abordées

- Comparative analysis of newspapers: https://www.aclweb.org/anthology/Y13-1047.pdf
- OCR : Tesseract, google vision ...
- Latent Dirichlet allocation: https://rstudio-pubs-static.s3.amazonaws.com/79360_850b2a69980c4488b1db95987a24867a.html
- Embeddings: https://fr.wikipedia.org/wiki/Word-embedding





Résolution automatique de jeux




MOTS CROISES

HORIZONTALEMENT A- Organisation et gestion d'une entreprise. B- Match nul. Fin de forme verbale. C- Démonstratif. Celui du loto est diffusé sur le petit écran. D- Jouer le boute-en-train. Service de réparations. E- Louer un navire marchand. Le pilote et l'architecte en ont l'utilité. F- S'il n'est pas chaton, il s'enroule facilement. Personnage de crèche provençale. G- Baldaquins. Il suit le dessert. H- Sujet pour homme. Son coup fait mal au cou. I- Choisie. Elle débute par une fête. J- Neige persistante. Effectifs.

VERTICALEMENT

 Professionnel du moulin, mais pas meunier. 2- En position pour prier. 3- Parle du nez. Rayons dont if ne faut pas abuser. 4- L'aluminium du chimiste. De couleur ambrée et de consistance sirupeuse et sucrée. 5- Abris pour hases et levrauts. Possessif. 6- Augmenter les dimensions. Score idéal pour un golfeur. 7- Réserve naturelle de sel. Elle se développe sous terre. 8- Carte maîtresse. Son ouverture et sa fermeture règlent le débit de l'eau. 9-Epreuve photographique. Article étranger. 10- Cessez-le-feu. Eacon d'être.







Résolution automatique de jeux

Thématiques

- OCR
- Grid extraction
- Solveur de jeux

Champs d'application

- Extraction d'information
- Algorithmique

- Extraction de grille
 - http://honors.cs.umd.edu/uploads/thesis/file/178/Thesis.pdf
 - https://github.com/dgulotta/cross2sheet
 - https://github.com/HartasCuerdas/xwbinarify
- Solveur (exemple pour le sudoku)
 - http://igm.univ-mlv.fr/~dr/XPOSE2013/sudoku/





Emissions Radio: les données




Du 2 Septembre 2019 au 26 septembre 2019





L'actu sur la plage horaire 7h-9h





Fichier *donnees_radio.csv* contenant les émissions découpées en segments avec les colonnes suivantes :

- debut_seg : temps de début du segment (cs)
- duree_seg : durée du segment (cs)
- **genre** : genre du locuteur (M ou F)
- locuteur : identifiant du locuteur (par émission/jour)
- **texte**: texte transcrit (sans ponctuation)
- date : date de l'émission (AAAA-MM-JJ)
- emission : émission





Emissions Radio: les données

Un fichier *donnees_radio_thematisees.csv* contenant les émissions découpées en segments / groupes de souffle / mots lemmatisés. Ce fichier contient les colonnes suivantes :

- id_emission : concaténation de la chaîne Radio et de la date
- id_segment : Identifiant du segment
- **mot** : mot
- id_GS: identifiant du groupe de souffle
- cluster : cluster thématique auquel le mot appartient (tous les mots d'un groupe de souffle appartiennent au même cluster

Note : un groupe de souffle est un ensemble de mots prononcés sans prendre de pause de respiration.





Résumé de l'actualité

Thématiques

- Text summarization
- Topic modeling

Champs d'application

- Exploration de documents
- Traitement de données textuelles
- Visualisation de texte

- Text summarization
 - https://arxiv.org/pdf/1801.10198v1.pdf
 - https://www.aclweb.org/anthology/W17-1003.pdf
- Evaluation : https://rxnlp.com/how-rouge-works-for-evaluation-of-summarization-tasks/

- https://github.com/miso-belica/sumy
- https://github.com/mathsyouth/awesome-textsummarization
- https://arxiv.org/ftp/arxiv/papers/1304/1304.2476
 .pdf





Identification des locuteurs

Thématiques

- Détection des entités nommées
- Identification des rôles/relations

Champs d'application

- Extraction d'informations
- Structuration de l'information
- Visualisation de relations

- https://fr.wikipedia.org/wiki/Reconnaissance_d%27entit%C3%A9s_nomm%C3%A9es
- https://github.com/JuneFeng/RelationClassification-RL
- https://arxiv.org/pdf/1904.10887.pdf





Comparaison du traitement d'un sujet d'actualité

Thématiques

- Détection de thématiques / sujets traités
- Analyse de sentiments
- Word embedding

Champs d'application

- Exploration de base documentaire
- Etude de verbatims
- Détection de thématiques abordées

- Détection de thématiques : https://openclassrooms.com/fr/courses/4470541-analysez-vos-donnees-textuelles/4855011-modelisez-des-sujets-avec-des-methodes-non-supervisees
- Word embedding :
 - <u>https://openclassrooms.com/fr/courses/4470541-analysez-vos-donnees-textuelles/4855006-effectuez-des-plongements-de-mots-word-embeddings</u>
 - https://fr.wikipedia.org/wiki/Word_embedding
- Analyse de sentiment : https://towardsdatascience.com/sentiment-analysis-concept-analysis-and-applications-6c94d6f58c17



Livrables

- Un document PowerPoint de 15 slides maximum présentant l'objectif fixé, la démarche méthodologique, les traitements réalisés, les résultats obtenus et commentés et des scénarios d'application.
- Le code, qui pourra être partagé sur Gitea

Optionnel:

Une vidéo ou tout support animé de trois minutes maximum





Evaluation

- Pour évaluer les restitutions, le jury se basera sur les critères suivants :
 - Originalité et pertinence de l'approche
 Ce critère juge de l'originalité de la démarche retenue et de la pertinence des traitements effectués
 - Expertise technique & méthodologique
 Ce critère vise à mesurer les techniques utilisées pour traiter la problématique
 - Qualité des livrables
 Ce critère évalue la qualité du code et de la présentation PPT proposée (forme, pédagogie, illustration...)





Composition du jury

- Un jury constitué de profils complémentaires
 - Sydney BECU, Data Scientist
 - François VIEILLE, Data Scientist
 - Dorothée DELAUNAY, Responsable de l'Innovation
 - Maxime BOURSIN, Responsable des Offres
 - Edouard STEVENINI, Business Manager





Planning

Les grandes dates

| LUN | MAR | MER | JEU | VEN | SAM | DIM |
|-----|-----|-----|-----|-------|------|-----|
| | | | (| Octob | re 2 | 019 |
| | 1 | 2 | 3 | 4 | 5 | 6 |
| 7 | 8 | 9 | 10 | 11 | 12 | 13 |
| 14 | 15 | 16 | 17 | 18 | 19 | 20 |
| 21 | 22 | 23 | 24 | 25 | 26 | 27 |
| 28 | 29 | 30 | 31 | | | |

| LUN | MAR | MER love | JEU mbre | VEN 201 | SAM 9 | DIM |
|-----|-----|-------------|-------------|---------|----------|-----|
| | | | | 1 | 2 | 3 |
| 4 | 5 | 6 | 7 | 8 | 9 | 10 |
| 11 | 12 | 13 | 14 | 15 | 16 | 17 |
| 18 | 19 | 20 | 21 | 22 | 23 | 24 |
| 25 | 26 | 27 | 28 | 29 | 30 | |

| LUN Déc | MAR cemb | MER re 20 | JEU 19 | VEN | SAM | DIM |
|------------|-------------|--------------|-----------|-----|-----|-----|
| | | | | | | 1 |
| 2 | 3 | 4 | 5 | 6 | 7 | 8 |
| 9 | 10 | 11 | 12 | 13 | 14 | 15 |
| 16 | 17 | 18 | 19 | 20 | 21 | 22 |
| 23 | 24 | 25 | 26 | 27 | 28 | 29 |
| 30 | 31 | | | | | |

| | 29/10 Soirée de lancement |
|------------------------------|---|
| | 30/10 Envoi des données et des consignes |
| | 04/11 Remontée du sujet choisi par les équipes |
| <u>Q</u> Q [†] Q | 19/11 Atelier d'avancement (optionnel) |
| | 02/12 Fin du challenge : remise des livrables |
| | 06/12 Annonce des finalistes |

10/12 Soirée de clôture : présentation & remise des prix



Soirée de clôture

- 06 décembre : le jury annoncera la liste des équipes qui seront amenées à présenter leurs travaux lors de la soirée de clôture
- Programme du 10 décembre
 - Bilan par l'équipe organisatrice
 - Tour de table des équipes : 2 min par équipe pour présenter sa démarche
 - Présentation par les équipes finalistes : 10 minutes par équipe
 - Podium et remise des prix
 - Cocktail dînatoire

A l'issue du challenge, toutes les restitutions seront partagées à l'ensemble des participants





Merci à tous

A vous de jouer!